

## ① Формулировка задачи

- Векторы признаков  $\vec{x}_1, \dots, \vec{x}_L$  для  $L$  объектов.

↓ (известные значения)

$$y_1, \dots, y_L$$

- $\hat{y}_i \approx \tilde{y}_i = \langle \vec{\omega}, \vec{x}_i \rangle = \vec{\omega}^T \vec{x}_i$ .

- $Q(\vec{\omega}) = \sum_{i=1}^L L(y_i, \hat{y}_i) \rightarrow \min_{\vec{\omega}}$ .

- Используем квадратичную функцию потерь:  $L(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2$ .

- $X = \begin{bmatrix} \vec{x}_1^T \\ \vdots \\ \vec{x}_L^T \end{bmatrix}$  — матрица признаков;  $\vec{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_L \end{bmatrix}$ ,  $\vec{\hat{y}} = \begin{bmatrix} \hat{y}_1 \\ \vdots \\ \hat{y}_L \end{bmatrix}$ .

$$1) \hat{y}_i = \langle \vec{\omega}, \vec{x}_i \rangle = \langle \vec{x}_i, \vec{\omega} \rangle = \vec{x}_i^T \vec{\omega};$$

$$\Rightarrow \boxed{\vec{\hat{y}} = X \vec{\omega}}$$

$$2) \underline{Q(\vec{\omega})} = \sum_{i=1}^L L(y_i, \hat{y}_i) = \sum_{i=1}^L (y_i - \hat{y}_i)^2 = (\|\vec{y} - \vec{\hat{y}}\|_2)^2 = \underline{\|\vec{y} - X \vec{\omega}\|_2^2};$$

- $$3) \hat{y} \text{ принадлежит подпространству } L(X) \text{ в } \mathbb{R}^n, \text{ порождаемый столбцами } \vec{x}^1, \dots, \vec{x}^L \text{ матрицы } X.$$

## ② Нормальное уравнение

$$1) \text{ Доказать: } \frac{\partial}{\partial \vec{x}} (A \vec{x} + \vec{b})^T (A \vec{x} + \vec{b}) = 2 A^T (A \vec{x} + \vec{b}).$$

- Покажем, что  $\frac{\partial}{\partial \vec{x}} (\vec{x}^T \vec{b}) = \vec{b}$ :

$$\vec{x}^T \vec{b} = (x_1 \dots x_n) \cdot \begin{pmatrix} b_1 \\ \vdots \\ b_n \end{pmatrix} = x_1 b_1 + \dots + x_n b_n$$

$$\frac{\partial (\vec{x}^T \vec{b})}{\partial \vec{x}} = \begin{bmatrix} \frac{\partial (\vec{x}^T \vec{b})}{\partial x_1} \\ \vdots \\ \frac{\partial (\vec{x}^T \vec{b})}{\partial x_n} \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_n \end{bmatrix} = \vec{b}.$$

$$\text{Аналогично получим } \frac{\partial}{\partial \vec{x}} (\vec{b}^T \vec{x}) = \vec{b}.$$

- Также покажем, что  $\frac{\partial}{\partial \vec{x}} (\vec{x}^T A \vec{x}) = (A + A^T) \vec{x}.$

$$A \vec{x} = \begin{bmatrix} a_{11}x_1 + \dots + a_{1n}x_n \\ \vdots \\ a_{n1}x_1 + \dots + a_{nn}x_n \end{bmatrix}, \quad \vec{x}^T A \vec{x} = x_1(a_{11}x_1 + \dots + a_{1n}x_n) + \dots + x_n(a_{n1}x_1 + \dots + a_{nn}x_n)$$

$$\frac{\partial}{\partial \vec{x}}(\dots) = \begin{bmatrix} \frac{\partial(\dots)}{\partial x_1} \\ \vdots \\ \frac{\partial(\dots)}{\partial x_n} \end{bmatrix}; \quad \frac{\partial}{\partial \vec{x}}(\vec{x}^T A \vec{x}) = \begin{bmatrix} (2a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n) + a_{21}x_2 + \dots + a_{n1}x_n \\ a_{12}x_2 + (2a_{22}x_2 + a_{21}x_1 + \dots + a_{2n}x_n) + \dots + a_{n2}x_n \\ \vdots \\ a_{1n}x_1 + \dots + a_{n-1,n}x_{n-1} + (2a_{nn}x_n + a_{n1}x_1 + \dots + a_{n,n-1}x_{n-1}) \end{bmatrix} = \begin{bmatrix} x_1(a_{11}+a_{11}) + x_2(a_{12}+a_{21}) + \dots + x_n(a_{1n}+a_{n1}) \\ x_1(a_{12}+a_{21}) + x_2(a_{22}+a_{22}) + \dots + x_n(a_{2n}+a_{n2}) \\ \vdots \\ x_1(a_{1n}+a_{n1}) + \dots + x_n(a_{nn}+a_{nn}) \end{bmatrix} = (A + A^T) \vec{x}$$

$$\begin{aligned} \cdot \frac{\partial}{\partial x} [(Ax+b)^T (Ax+b)] &= \frac{\partial}{\partial x} [(x^T A^T + b^T)(Ax+b)] = \frac{\partial}{\partial x} [x^T A^T A x + x^T A^T b + b^T A x + b^T b] \\ &= \frac{\partial}{\partial x} (x^T A^T A x) + \frac{\partial}{\partial x} (x^T A^T b) + \frac{\partial}{\partial x} (b^T A x) + \frac{\partial}{\partial x} (b^T b) \xrightarrow{0} = \\ &= (A^T A + (A^T A)^T) x + A^T b + (b^T A)^T = 2A^T A x + 2A^T b = \underline{\underline{2A^T(Ax+b)}} \end{aligned}$$

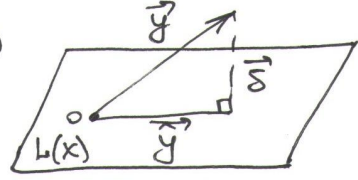
$$2) Q(\omega) = \|y - X\omega\|_2^2 = \|X\omega - y\|_2^2 = (X\omega - y)^T (X\omega - y)$$

$$\frac{\partial Q}{\partial \omega} = \frac{\partial}{\partial \omega} [(X\omega - y)^T (X\omega - y)] = 2X^T (X\omega - y) = 0.$$

$$2X^T X\omega - 2X^T y = 0.$$

$$\boxed{\omega = (X^T X)^{-1} X^T y}$$

### ③ Геометрическая интерпретация

1)   $\vec{y}$  - проекция вектора  $\vec{y}$  на  $L(X)$ ,  
 $\vec{s} = \vec{y} - \vec{\tilde{y}}$  - вектор остатков.  
 $\vec{s} \perp \vec{x}^{(j)} \forall j$  по свойству проекции.

Следовательно,  $\langle \vec{x}^{(j)}, \vec{y} - \vec{\tilde{y}} \rangle = -\langle \vec{x}^{(j)}, \vec{s} \rangle = 0$ .

$$2) X^T (\vec{\tilde{y}} - \vec{y}) = \begin{bmatrix} \vec{x}^{(1)} \\ \vdots \\ \vec{x}^{(L)} \end{bmatrix} \cdot (\vec{\tilde{y}} - \vec{y}) = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix} = \vec{0}.$$

$$3) X^T (\vec{\tilde{y}} - \vec{y}) = 0 \Rightarrow X^T (X\vec{\omega} - \vec{y}) = 0 \Rightarrow X^T X \vec{\omega} - X^T \vec{y} = 0 \Rightarrow$$

$$\boxed{\vec{\omega} = (X^T X)^{-1} X^T \vec{y}}$$



#### ④ Вероятностная интерпретация,

$$4) f(x, \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

$\vec{\theta} = (\mu, \sigma^2)$  - оцениваемые параметры

$x_1, \dots, x_n$  - выборка.

$$\mathbf{L}(x_1, \dots, x_n, \vec{\theta}) = \prod_{i=1}^n f_{\vec{\theta}}(x_i).$$

$$\vec{\theta} = \arg \max_{\vec{\theta}} \mathbf{L}(x_1, \dots, x_n, \vec{\theta}); \begin{cases} \nabla_{\vec{\theta}} \ln L = 0, \\ \nabla_{\vec{\theta}}^2 \ln L < 0. \end{cases}$$

$$5) y_i = \hat{y}_i + \varepsilon = \vec{x}_i^T \vec{w} + \varepsilon, \text{ где } \varepsilon \sim \mathcal{N}(0, \sigma^2) \quad \forall i = \overline{1, L}$$

$$L(x_1, \dots, x_L, \vec{w}) = \prod_{i=1}^L f_{\vec{w}}(\varepsilon_i) = \prod_{i=1}^L \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{\varepsilon_i^2}{2\sigma^2}\right),$$

$$\ln L = -L \ln(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^L \varepsilon_i^2,$$

$$\ln L \propto - \sum_{i=1}^L \varepsilon_i^2 = - \sum_{i=1}^L (y_i - \vec{x}_i^T \vec{w})^2 = - \|\vec{y} - X\vec{w}\|_2^2.$$

$$6) \ln L(x_1, \dots, x_L, \vec{w}) \rightarrow \max_{\vec{w}} \Leftrightarrow \|\vec{y} - X\vec{w}\|_2^2 \rightarrow \min_{\vec{w}}.$$

7) Воспользуемся распределением Лапласа:  $f(\varepsilon_i) = \frac{\alpha}{2} \exp(-\alpha|\varepsilon_i|)$ .

$$\ln L(\vec{x}, \vec{w}) \propto - \sum_{i=1}^L |\varepsilon_i| = - \sum_{i=1}^L |y_i - \vec{x}_i^T \vec{w}| = - \|\vec{y} - X\vec{w}\|_1.$$

#### ⑤ $L_2$ -регуляризация: штрафная регрессия (ridge regression),

$$8) Q(\vec{w}) = \|X\vec{w} - \vec{y}\|_2^2 + \tau \|\vec{w}\|_2^2, \quad \|\vec{w}\|_2^2 = \vec{w}^T \vec{w}, \quad \frac{\partial}{\partial \vec{w}} \|\vec{w}\|_2^2 = \vec{w} + \vec{w}.$$

$$\frac{\partial Q(\vec{w})}{\partial \vec{w}} = \frac{\partial}{\partial \vec{w}} \|X\vec{w} - \vec{y}\|_2^2 + \tau \frac{\partial}{\partial \vec{w}} \|\vec{w}\|_2^2 = 2X^T(X\vec{w} - \vec{y}) + 2\tau \vec{w} = 0.$$

$$2X^T X \vec{w} - 2X^T \vec{y} + 2\tau \vec{w} = 0.$$

$$9) (X^T X + \tau I) \vec{w} = X^T \vec{y}$$

$$\boxed{\vec{w} = (X^T X + \tau I)^{-1} X^T \vec{y}}$$

10) Обозначим:  $A = X^T X$ ,  $B = X^T X + \tau I = A + \tau I$ .

• рассмотрим собствен. значения (~~и соответ. векторы~~) матрицы  $A$ :

$$(A - \lambda I) \vec{x} = 0 \Rightarrow \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n - \text{собств. знач. матрицы } A.$$

• собствен. значения матрицы  $B$ :

$$(B - \lambda' I) \vec{x} = 0 \rightarrow (A + \tau I - \lambda' I) \vec{x} = 0 \rightarrow (A - (\lambda' - \tau) I) \vec{x} = 0.$$

обозначим  $\lambda^* = \lambda' - \tau$ , тогда:  $(A - \lambda^* I) \vec{x} = 0$ .

Снова получим собствен. знач. матрицы  $A$ :  $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ , ~~то они~~ связаны с собствен. значениями матрицы  $B$ :  $\lambda'_i = \lambda_i + \tau$ ,  $i = \overline{1, n}$ .

•  $\lambda_{\min}(A) = \lambda_1$ ;  $\lambda_{\max}(A) = \lambda_n$ ;  
 $\lambda_{\min}(B) = \lambda_1 + \tau$ ;  $\lambda_{\max}(B) = \lambda_n + \tau$ .

• рассмотрим число обусловленности матриц  $A$  и  $B$ .

$$\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)} = \frac{\lambda_n}{\lambda_1} >$$

покажем, что  $\kappa(A) \geq \kappa(B)$ :

$$\frac{\lambda_n}{\lambda_1} \geq \frac{\lambda_n + \tau}{\lambda_1 + \tau} \quad \text{~~не так~~}$$

$$\kappa(B) = \frac{\lambda_{\max}(B)}{\lambda_{\min}(B)} = \frac{\lambda_n + \tau}{\lambda_1 + \tau}.$$

$$\frac{\lambda_1 \lambda_n + \tau \lambda_n}{\lambda_1 (\lambda_1 + \tau)} \geq \frac{\lambda_1 \lambda_n + \lambda_1 \tau}{\lambda_1 (\lambda_1 + \tau)} \quad (\text{верно, т.к. } \lambda_n \geq \tau)$$

$\Rightarrow \kappa(A) \geq \kappa(B)$ : число обусловленности новой матрицы уменьшилось.  
 (это хорошо)

•  $A: (A - \lambda I) \vec{x} = 0$ ,  
 $B: (A - \lambda I) \vec{x} = 0$ .  $\rightarrow$  собственные векторы матриц  $A$  и  $B$  совпадают.  
 (в  $(B - \lambda' I) \vec{x} = 0$ )

## ⑥ $L_1$ -регуляризация: лассо-регрессия (LASSO)

1.1) Рассмотрим задачу минимизации:

$$\begin{cases} Q(\omega) \rightarrow \min_{\omega}, \\ \|\omega\|_{L_1} \leq r. \end{cases}$$

Запишем лагранжиан данной задачи:

$$L(\omega, \tau) = Q(\omega) + \tau (\|\omega\|_{L_1} - r), \quad \tau \geq 0.$$


$$\nabla_{\omega} L(\omega, \tau) = \nabla_{\omega} (Q(\omega) + \tau \|\omega\|_{L_1}) = 0.$$

$\Rightarrow$  добавление ограничения  $\|\omega\|_{L_1} \leq r$  равносильно добавлению штрафного слагаемого  $\tau \|\omega\|_{L_1}$  в функционал для некоторого  $\tau$ .




$$12) \begin{cases} Q(\omega) \rightarrow \min_{\omega} \\ \|\omega\|_{L_1} \leq r. \end{cases}$$

Чаще всего линии уровня пересекаются с шаром  $L_1$ -норма в угловых точках (иногда в касательных точках).



Если рассмотреть линейную аппроксимацию линии уровня в точках пересечения:




## 7) Дополнительные вопросы

$$13) y_i = \hat{y}_i + \varepsilon_i = \sum_{j=1}^n x_i^{(j)} \omega_j + \omega_0 + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2) \quad \forall i = \overline{1, L}.$$

$$\mathbb{E} y_i = \sum_{j=1}^n \omega_j \mathbb{E} x_i^{(j)} + \omega_0.$$

Если отцентрировать выборку, то  $\mathbb{E} y_i = 0$ ,  $\mathbb{E} x_i^{(j)} = 0$ ,  $j = \overline{1, n}$ ,  $i = \overline{1, L}$

Следовательно,  $\omega_0 = 0$ .



$$\text{гипотеза: } \omega_x x + \omega_y y + \omega_0 = 0,$$

$$\text{квадрат расстояния } p_i^2 = \frac{(\omega_x x_i + \omega_y y_i + \omega_0)^2}{\omega_x^2 + \omega_y^2},$$

$$Q = \sum_{i=1}^n p_i^2 \rightarrow \min_{\omega_0, \omega_x, \omega_y} \Rightarrow \underline{\underline{\nabla Q = 0.}}$$

Отнормируем гипотезу:  $\omega_x^2 + \omega_y^2 = 1$ .

$$\nabla Q = \begin{pmatrix} \frac{\partial Q}{\partial \omega_0} \\ \frac{\partial Q}{\partial \omega_x} \\ \frac{\partial Q}{\partial \omega_y} \end{pmatrix} = 0.$$

$$\hookrightarrow p_i^2 = (\omega_x x_i + \omega_y y_i + \omega_0)^2.$$

$$\begin{aligned} \bullet \frac{\partial Q}{\partial \omega_0} &= \sum_{i=1}^n \frac{\partial p_i^2}{\partial \omega_0} = \sum_{i=1}^n 2(\omega_x x_i + \omega_y y_i + \omega_0) = 2\omega_x \cdot n\bar{x} + 2\omega_y \cdot n\bar{y} + 2n\omega_0 = \\ &= 2n(\omega_x \bar{x} + \omega_y \bar{y} + \omega_0) = 0 \Rightarrow \boxed{\omega_x \bar{x} + \omega_y \bar{y} + \omega_0 = 0} \end{aligned}$$

$$\cdot \frac{\partial Q}{\partial \omega_x} = \sum_{i=1}^n \frac{\partial p_i^2}{\partial \omega_x} = \sum_{i=1}^n 2(\omega_x x_i + \omega_y y_i + \omega_0) x_i = 2\omega_x \sum_{i=1}^n x_i^2 + 2\omega_y \sum_{i=1}^n x_i y_i +$$

$$+ 2\omega_0 n \bar{x} = 2n(\omega_x \bar{x}^2 + \omega_y \bar{x}\bar{y} + \omega_0 \bar{x}) = 0.$$

$$\Rightarrow \boxed{(\omega_x \bar{x}^2 + \omega_y \bar{x}\bar{y} + \omega_0 \bar{x}) = 0}$$

$$\cdot \frac{\partial Q}{\partial \omega_y} = \sum_{i=1}^n \frac{\partial p_i^2}{\partial \omega_y} = \sum_{i=1}^n 2(\omega_x x_i + \omega_y y_i + \omega_0) y_i = 2n(\omega_x \bar{x}\bar{y} + \omega_y \bar{y}^2 + \omega_0 \bar{y}) = 0.$$

$$\Rightarrow \boxed{\omega_x \bar{x}\bar{y} + \omega_y \bar{y}^2 + \omega_0 \bar{y} = 0}$$

Tогда: 
$$\begin{cases} (1) \omega_x \bar{x} + \omega_y \bar{y} + \omega_0 = 0, \rightarrow \omega_0 = -\omega_x \bar{x} - \omega_y \bar{y} \\ (2) \omega_x \bar{x}^2 + \omega_y \bar{x}\bar{y} + \omega_0 \bar{x} = 0, \\ (3) \omega_x \bar{x}\bar{y} + \omega_y \bar{y}^2 + \omega_0 \bar{y} = 0. \end{cases}$$

$$(2): \omega_x \bar{x}^2 + \omega_y \bar{x}\bar{y} - \omega_x \bar{x}^2 - \omega_y \bar{x}\bar{y} = 0.$$

$$\omega_y = \omega_x \frac{(\bar{x}^2 - \bar{x}^2)}{(\bar{x}\bar{y} - \bar{x}\bar{y})}$$

подставим в первую: 
$$\omega_x^2 + \omega_x^2 \left( \frac{\bar{x}^2 - \bar{x}^2}{\bar{x}\bar{y} - \bar{x}\bar{y}} \right)^2 = 1.$$

$$\Rightarrow \boxed{\omega_x = \left( 1 + \left( \frac{\bar{x}^2 - \bar{x}^2}{\bar{x}\bar{y} - \bar{x}\bar{y}} \right)^2 \right)^{-1/2}}$$

$$\Rightarrow \boxed{\omega_y = \omega_x \left( \frac{\bar{x}^2 - \bar{x}^2}{\bar{x}\bar{y} - \bar{x}\bar{y}} \right)}$$

$$\Rightarrow \boxed{\omega_0 = - \frac{\omega_x \bar{x}\bar{y} + \omega_y \bar{y}^2}{\bar{y}}}$$