

# Листок по теме «Линейная регрессия»

Кантор Виктор

16 февраля 2018 г.

## 1 Формулировка задачи

Пусть, для начала, есть векторы признаков  $x_1, \dots, x_l$  для  $l$  объектов. На них же известны значения прогнозируемой величины  $y_1, \dots, y_l$ . Будем пытаться аппроксимировать зависимость этой величины от признаков линейной:  $y \approx \hat{y} = \langle w, x \rangle = w^T x$ , где  $w$  - вектор параметров, который мы хотим настроить на обучающей выборке. Здесь мы также имеем ввиду, что могли бы рассматривать более широкий класс зависимостей  $\hat{y} = \langle w, x \rangle + w_0$ , но мысленно добавив к  $x$  фиктивный признак  $x_0 = 1$  (равный единице для всех объектов), мы всегда сведем задачу к предыдущей.

Пусть, далее, мы хотим минимизировать суммарную потерю на обучающей выборке:

$$Q(w) = \sum_{i=1}^l L(y_i, \hat{y}_i) \rightarrow \min_w$$

И пусть, кроме того, функция потерь квадратичная:  $L(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2$ .

Наконец, пусть  $X$  - матрица признаков, строки которой соответствуют признаковым описаниям объектов  $x_1, \dots, x_l$  (т.е. в матрице  $l$  строк), вектором  $y$  будем обозначать вектор длины  $l$  с координатами  $y_i$ , вектором  $\hat{y}$  - вектор длины  $l$  с координатами  $\hat{y}_i$ .

1. Как тогда выразить вектор  $\hat{y}$  через  $w$  и  $X$ ?
2. Как записать функционал  $Q(w)$  через  $\hat{y}$  и  $y$ ? Что получится, если подставить выражение для  $\hat{y}$ ?
3. Как выражается  $\hat{y}$  через столбцы матрицы  $X$ ? В каком линейном пространстве лежит  $\hat{y}$  (в терминах линейных оболочек набора векторов)?

## 2 Нормальное уравнение (normal equation)

1. Покажите справедливость следующего выражения:

$$\frac{\partial}{\partial x} (Ax + b)^T (Ax + b) = 2A^T (Ax + b)$$

2. Приравняв производную  $Q(w)$  по вектору  $w$  к нулю, выразите вектор весов  $w$  в точке минимума через  $X$  и  $y$ . Полученное выражение носит название *NormalEquation*. Запомните, как оно получается — пригодится на экзамене.

### 3 Геометрическая интерпретация

1. Вспомните, что у вас получалось в последнем вопросе из раздела "формулировка задачи". Мы хотим минимизировать сумму квадратов отклонений, значит мы хотим для заданного вектора  $y$  найти в этом линейном пространстве точку  $\hat{y}$ , которая будет самой близкой к вектору  $y$ . Нетрудно сообразить, что такой точкой будет проекция  $y$  на линейное пространство, в котором должен жить  $\hat{y}$ . Чему в этом случае равно скалярное произведение  $\langle x^{(j)}, \hat{y} - y \rangle$ , где  $x^{(j)}$  -  $j$ -ый столбец матрицы  $X$ ?
2. Исходя из предыдущего пункта, чему будет равно произведение

$$X^T(\hat{y} - y) \text{ ?}$$

3. Закончите геометрический вывод нормального уравнения, подставив сюда выражение для  $\hat{y}$  и выразив  $w$ .

### 4 Вероятностная интерпретация

4. Вспомните формулу плотности одномерного нормального распределения и как оцениваются параметры распределения методом максимального правдоподобия.
5. Предположим, что для каждого объекта  $x_i$  наблюдаемое значение величины  $y_i$  распределено нормально с матожиданием  $\hat{y}_i$  (некоторым "истинным значением" в рамках линейной модели, которое мы хотим оценить) и дисперсией  $\sigma^2$ , одинаковой для всех  $i$ . Напишите минимизируемый функционал в задаче оценки  $\hat{y}_i$  по методу максимального правдоподобия.
6. Покажите, что метод максимального правдоподобия в этом случае приводит к минимизации суммы квадратов отклонений.
7. Теперь вы видите, что есть связь между функцией потерь и нашим представлением о распределении "правильных ответов". А какое распределение привело бы к минимизации суммы модулей отклонений?

### 5 $l_2$ -регуляризация: гребневая регрессия (ridge regression)

8. Давайте теперь добавим к функционалу  $Q(w)$  штрафное слагаемое  $\tau \|w\|^2$ . Дифференцируя по вектору  $w$  получите новое выражение для его оптимального значения.
9. Покажите, что это дает тот же результат, что и добавление к матрице  $X^T X$  единичной матрицы  $I$ , умноженной на  $\tau$  (с последующим применением стандартной формулы).

10. Модификация матрицы из предыдущего пункта изменяет собственные числа матрицы, меняя число обусловленности и позволяя обратить  $X^T X$ , если до модификации обращение было неустойчиво. Но при этом сохраняются собственные векторы матрицы. Покажите, как меняются минимальное и максимальное собственное число и число обусловленности матрицы. А затем, — что собственные векторы остаются теми же.

## 6 $l_1$ -регуляризация: лассо Тибширани (LASSO)

11. Применив теорему Куна-Таккера, покажите, что добавление ограничения  $\|w\|_{l_1} < r$  равносильно добавлению штрафного слагаемого  $\tau\|w\|_{l_1}$  в функционал  $Q(w)$  для некоторого  $\tau$ .
12. Попробуйте с помощью теоремы или из геометрических соображений объяснить, почему минимум попадает в "угловые точки" шаров  $l_1$ -нормы (т.е. почему зануляются некоторые коэффициенты  $w$ ), и почему с увеличением  $\tau$  нулей будет становиться больше.

## 7 Дополнительные вопросы

13. Покажите, что если предварительно центрировать выборку, параметр сдвига  $w_0$  получится равным нулю.
14. Представьте теперь, что вы пытаетесь восстановить прямую по известным ее точкам на изображении. Здесь вам уже захочется минимизировать не сумму квадратов отклонений по  $y$ , а сумму квадратов расстояний от известных точек до прямой. Как в этом случае будут выглядеть формулы для коэффициентов искомой прямой  $w_x x + w_y y + w_0 = 0$ ?
15. Придумайте изящный ответ на предыдущий вопрос с помощью метода главных компонент.